

Optimización de la Estación CALLISTO e Implementación de un Sistema de Detección Automática de Ráfagas de Radio Solares

Iván González¹, Dr. Diego Stalder², Dr. Jorge Molina³

¹Alumno, Facultad de Ingeniería. Universidad Nacional de Asunción. San Lorenzo, Paraguay

²Orientador, Facultad de Ingeniería. Universidad Nacional de Asunción. San Lorenzo, Paraguay

³Orientador, Facultad Politécnica. Universidad Nacional de Asunción. San Lorenzo, Paraguay

Palabras clave:

- SRB
- CNN
- VGG16
- AlexNet

Resumen

Este trabajo abarca la optimización integral de la estación CALLISTO en Paraguay, que busca detectar los excesos de radiación causados por las tormentas solares en el espectro de ondas de radio. Estos excesos de radiación, son denominados Ráfagas de Radio Solares (SRB), y se observan en el área del clima espacial para mitigar los daños que pueden causar las tormentas solares en los sistemas de comunicación. Se realizaron varios experimentos, como la integración del procesador RaspBerry Pi en la adquisición de datos, mediciones del espectro en varias ubicaciones para seleccionar el nuevo lugar de la estación, y un minucioso análisis con el Divisor Wilkinson para la ampliación del rango espectral actual. Además, se diseñó satisfactoriamente un sistema de detección de SRB utilizando Aprendizaje Profundo.

Keywords

- SRB
- CNN
- VGG16
- AlexNet

Abstract

This work encompasses the comprehensive optimization of the CALLISTO station in Paraguay, aimed at detecting radiation surges caused by solar storms within the radio wave spectrum. These radiation surges, known as Solar Radio Bursts (SRB), are observed in space weather to mitigate the potential damages solar storms can cause upon communication systems. Various experiments were conducted, including the integration of the RaspBerry Pi processor in data acquisition, spectrum measurements at multiple locations to select the new station site, and a meticulous analysis with the Wilkinson Divider to extend the current spectral range. Additionally, a successful SRB detection system was designed using Deep Learning.

1. Introducción

Desde enero de 2022, Paraguay forma parte de la red internacional de espectrómetros solares denominada CALLISTO (Compound Astronomical Low cost Low frequency Instrument for Spectroscopy and Transportable Observatory). CALLISTO se utiliza para observar tormentas solares de radio con fines científicos, educativos y de divulgación, y también para promover la ciencia ciudadana [1]. Los datos obtenidos se utilizan para generar series de tiempo de las señales electromagnéticas y detectar los excesos de radiación causados por las tormentas solares en el espectro de ondas de radio. Estos excesos de radiación, son

denominados Ráfagas de Radio Solares (SRB) [2], y se observan en el área del clima espacial para mitigar los daños que pueden causar las tormentas solares en los sistemas de comunicación, navegación, tendidos eléctricos, naves espaciales y satélites.

Las SRB son un componente fundamental en el proceso que da lugar a las Fulguraciones Solares, las cuales pueden generar una Expulsión de Masa Coronal (CME) [3]. Existen cinco tipos principales de SRB, los cuales se clasifican en función de su morfología y velocidad de deriva en diferentes frecuencias: Tipo I, Tipo II, Tipo III, Tipo IV y Tipo V [4].

De acuerdo a la literatura [5], las SRB del Tipo I son breves y ocurren en el rango de frecuencias de

50 MHz a 500 MHz, generalmente asociadas a regiones activas del Sol. Por su parte, las del Tipo II disminuyen gradualmente su intensidad desde frecuencias altas a bajas, en el rango de 20 MHz a 150 MHz. Las del Tipo III, por otro lado, disminuyen rápidamente su intensidad desde frecuencias altas a bajas, y suelen estar asociadas a grandes fulguraciones solares. Las SRB del Tipo IV se caracterizan por tener una emisión continua en un amplio rango de frecuencias, con duraciones desde algunas horas hasta unos días, y se registran en el rango de 20 MHz a 2 GHz. Finalmente, las SRB del Tipo V ocurren como máximo a los 200 MHz y parecen surgir luego del decaimiento del Tipo III. Una parte de este trabajo se enfoca en diseñar un modelo de Inteligencia Artificial basado en Aprendizaje Automático, con el objetivo de detectar una SRB.

Además, para lograr la mejora integral de la estación, se propone la optimización de la estación. Con esto se abordan tres problemas: interferencias de radio, rango espectral limitado e interrupciones en el funcionamiento. Actualmente, la ubicación de la estación se ve afectada por interferencias de señales FM de alrededor de 100 MHz y señales de comunicaciones inalámbricas. Además, la estación posee un rango limitado que va de 45 MHz a 160 MHz, que podría extenderse hasta 800 MHz. Para hacer frente a los cortes de energía, también se requiere un sistema independiente que funcione con una fuente de energía portátil o batería.

2. Objetivos

2.1. Principal

Optimizar el desempeño de la estación CALLISTO e implementar un sistema de detección automática de ráfagas de radio solares mediante el uso de aprendizaje profundo, con el fin de contribuir al monitoreo y estudio de la actividad solar.

2.2. Específicos

- Evaluar y comparar distintos modelos de aprendizaje de máquina, incluyendo redes neuronales convolucionales, para la automatización de la estación, con el fin de seleccionar el más preciso y eficiente para la detección y clasificación de ráfagas solares.
- Construir una base de datos actualizada de observaciones de ráfagas solares utilizando el espectrómetro CALLISTO, incluyendo información detallada sobre la intensidad, frecuencia y tipo de ráfaga.
- Evaluar las posibles ubicaciones para la estación CALLISTO, teniendo en cuenta las fuentes de interferencia y la infraestructura disponible, con el

fin de seleccionar el mejor lugar posible y optimizar la capacidad de detección de ráfagas solares.

- Realizar un análisis de la ampliación del rango espectral de la estación CALLISTO, para mejorar la calidad y cantidad de información obtenida de las observaciones de ráfagas solares.
- Instalar un procesador Raspberry Pi para garantizar un funcionamiento continuo y sin interrupciones de la estación CALLISTO, asegurando así la eficacia y precisión de las observaciones de ráfagas solares.

3. Estado del Arte

Confeccionar una base de datos para todos los tipos requiere de mucho trabajo debido a la escasa cantidad de datos. Se presenta como una alternativa el método estadístico ya que no depende de la base de datos. El estudio de Singh de 2019 [6] utiliza este método para clasificar SRB del Tipo III, si bien no clasifica todos los tipos, aporta las herramientas que pueden ser aplicadas para un clasificador de varios tipos. Se obtuvo una tasa de verdaderos positivos del 95.67 %, aunque con una exactitud del 61.67 %, una exactitud baja que se atribuye principalmente al ruido. Luego, en la fase de pruebas del clasificador, lograron detectar 238 ráfagas del Tipo III que corresponden a todo el año 2014.

Las Redes Neuronales Convolucionales (CNN) sobresalen en la extracción de características mientras preservan las relaciones espaciales entre píxeles, logrado a través de la convolución. El estudio de Bussons [7] que utiliza la arquitectura CNN, mostró convergencia con el modelo AlexNet cuando se aplicó a su conjunto de datos de elaboración propia. Lo particular de este estudio es que redujeron la ventana de tiempo a 1 minuto, para que en caso de existir una ráfaga solar, esta sea la característica más notoria de la imagen. El resultado de la exactitud es de 93-96 %, mostrando una alta capacidad de detección.

Otro estudio (Rino, 2019) [8] también demostró efectividad con el uso de la CNN, incluso empleando una arquitectura simple y una base de datos muy limitada. A pesar de una base de datos no muy extensa, se obtuvo una precisión del 95 % para una estación, y del 90 % para otra.

4. Marco Teórico

En esta sección se abordan las teorías y conceptos fundamentales necesarios para llevar a cabo la experimentación de este trabajo. Se comienza con la definición de conceptos clave en la Inteligencia Artificial. Luego, se establecen las métricas de evaluación de los modelos desarrollados y los indicadores utilizados en la fase experimental para la optimización de la estación.

4.1. Aprendizaje automático

El objetivo principal del aprendizaje automático es realizar predicciones a partir de un conjunto de datos. Esto se logra mediante el entrenamiento de modelos que, de alguna manera, imitan el proceso de aprendizaje humano. En este caso, la experiencia enseña cómo obtener determinados resultados sin depender de instrucciones lógicas directas. La elección de el aprendizaje automático nace ante la necesidad de resolver dos aspectos importantes: la complejidad en la definición de parámetros y la capacidad de generalización en las predicciones.

4.2. Aprendizaje Profundo

Se refiere a la adquisición de conocimiento, a través del uso de Aprendizaje Automático que usa varios niveles para la extracción de la información. Para tareas de clasificación, las capas superiores de representación amplifican aspectos de la entrada que son importantes para la discriminación y suprimen variaciones irrelevantes. Las características aprendidas en la primera capa de representación generalmente representan la presencia o ausencia de bordes en orientaciones y ubicaciones específicas en la imagen. La segunda capa detecta típicamente patrones al identificar disposiciones particulares de bordes, independientemente de las pequeñas variaciones en las posiciones de los bordes. La tercera capa puede ensamblar estos patrones en combinaciones más grandes que corresponden a partes de objetos conocidos, y las capas posteriores detectarían objetos como combinaciones de estas partes.

4.3. Redes Neuronales

Es un modelo matemático compuesto por un gran número de elementos procesales organizados en niveles [9]. Están compuestas por unidades llamadas neuronas artificiales o nodos, organizadas en capas. Cada neurona recibe una o más entradas, las procesa utilizando una función de activación y produce una salida.

4.4. Redes Neuronales Convolucionales

Los nodos en las capas de convolución (ocultas) no están conectados simplemente a todos los nodos de la capa anterior como en una Red Neuronal convencional. Debido a que están optimizados para imágenes, los nodos de las CNN componen su entrada en pequeñas secciones de píxeles vecinos. Cada nodo luego aprende alguna característica de la imagen. En la Figura 1 se muestra la diferencia entre la Red Neuronal convencional y la CNN.

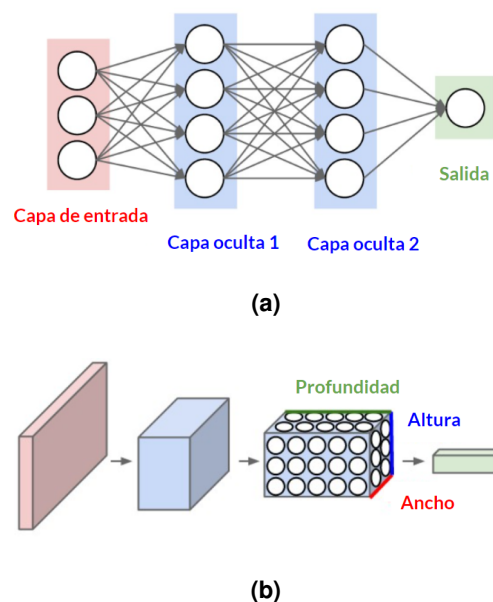


Figura 1: Figura a: Una red neuronal regular. Figura b: Cada capa de una CNN transforma un volumen de entrada 3D a un volumen de salida 3D. **Fuente:** www.cs231n.stanford.edu

4.5. Arquitecturas

Las arquitecturas de CNN utilizadas en este trabajo son VGG16 y AlexNet. La arquitectura VGG16, creada en el 2014, es una CNN con 16 capas de profundidad [10]. Mientras que AlexNet es una CNN con 8 capas de profundidad [11], con tamaño de la entrada de imagen de 227 por 227.

4.6. Métricas

A continuación, se definen las métricas que se utilizan para evaluar el rendimiento del modelo de detección y de la optimización de la estación.

4.6.1. Matriz de confusión

La matriz de confusión es una herramienta que permite visualizar el desempeño del modelo de clasificación. Está compuesta por filas y columnas que representan las etiquetas reales y las predicciones del modelo, respectivamente. La disposición comúnmente se presenta como en la Figura 2.

		PREDICCIÓN	
		Clase A	Clase B
REAL	Clase A	TP	FN
	Clase B	FP	TN

Figura 2: Ejemplo de matriz de confusión. **Fuente:** Elaboración propia.

La matriz de confusión proporciona la cantidad de Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN).

4.6.2. Exactitud

La exactitud (Acc del inglés *Accuracy*) es una métrica que indica el porcentaje de predicciones correctas sobre el total de datos,

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

4.6.3. Tasa de Falsos Negativos

La Tasa de Falsos Negativos (FNR el inglés *False Negative Rate*), es el porcentaje falsos negativos sobre el total de las clases positivas,

$$FNR = \frac{FN}{TP + FN} \quad (2)$$

4.6.4. Tasa de Falsos Positivos

La Tasa de Falsos Positivos (FPR el inglés *False Positive Rate*), es el porcentaje falsos positivos sobre el total de las clases negativas,

$$FPR = \frac{FP}{FP + TN} \quad (3)$$

También existen otras métricas que evalúan modelos de detección como la Tasa de Verdaderos Positivos o Recall (Rec), que evalúa la capacidad del modelo para identificar todas las clases positivas. La precisión (Pre) representa la proporción de casos positivos correctamente identificados en relación con el total de predicciones positivas. Asimismo, se emplea comúnmente el F1-Score, que es una medida de precisión para conjuntos de datos desbalanceados.

4.6.5. Razón de onda estacionaria

La Relación de Onda Estacionaria (ROE) se refiere a la razón geométrica existente entre el valor máximo y el valor mínimo de la amplitud de voltaje observado en una condición de onda estacionaria eléctrica como sería a lo largo de una línea de transmisión. Este fenómeno se explica mediante los conceptos de onda directa y onda reflejada.

Suponiendo, Potencia Directa = 100 %

- Con una ROE de 1, se tiene una Potencia Reflejada de 0 %
- Con una ROE de 2, se tiene una Potencia Reflejada de 11.1 %
- Con una ROE de 3, se tiene una Potencia Reflejada de 25 %

En términos prácticos, una ROE de 3 es el máximo valor aceptable [12]. Esta métrica se tiene en cuenta al momento de evaluar la optimización de la estación.

4.6.6. Ganancia de potencia eléctrica

Es otra métrica que se tiene en cuenta en la fase experimental de la optimización de la estación. Se representa mediante la siguiente ecuación,

$$G = \frac{P_o}{P_i} \quad (4)$$

dónde P_o es la potencia de salida y P_i es la potencia de entrada. Un resultado superior a 1 implica ganancia o amplificación, valores inferiores a 1, indican pérdidas o atenuación, mientras que si la resultante da 1, entonces los niveles de entrada y salida son iguales. En redes de radio es común usar el *dBm* (decibelio-milivatio) que es simplemente la razón de potencia expresada en decibelios (dB) relativa a un milivatio (mW).

5. Desarrollo del modelo de detección de ráfagas solares

Esta sección presenta la creación de la base de datos, el pre-procesamiento y el diseño del modelo de detección de SRB, siguiendo el diagrama de flujo mostrado en la Figura 3.

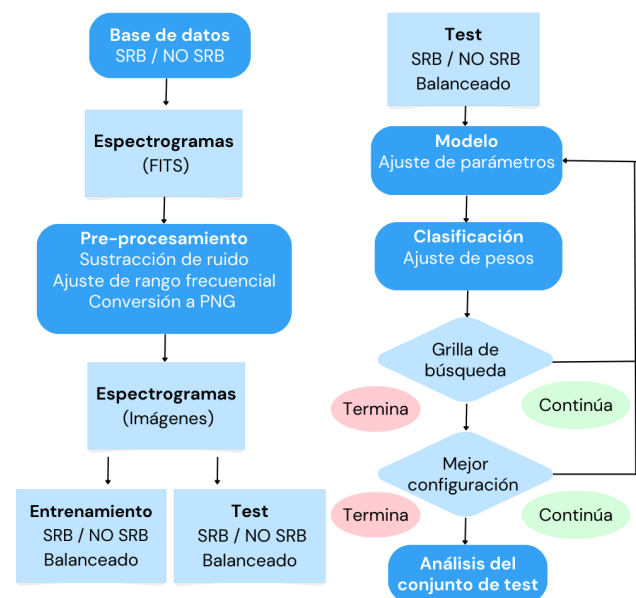


Figura 3: Diagrama de flujo del diseño del modelo de detección de ráfagas. **Fuente:** Elaboración propia.

A continuación, se detalla cada etapa de la metodología seguida.

5.1. Base de datos y Pre-procesamiento

Las clases están basadas en el reporte de detecciones de ráfagas solares diario encontrado en la página oficial de la red CALLISTO, que contiene información importante como la fecha, duración del evento, tipo de ráfaga y las estaciones que detectan dicho evento [13]. Usando este reporte, se creó un código de Python para descargar automáticamente los archivos que contienen ráfagas solares, así como aquellos sin ráfagas.

Posteriormente, los archivos descargados son convertidos a imágenes que conformarán la base de datos. Sin embargo, estas imágenes presentan altos niveles de ruido, caracterizado por franjas horizontales en determinados niveles de frecuencia, que son eliminados en la etapa de pre-procesamiento. La eliminación de ruido se consigue mediante la sustracción del fondo, que implica calcular la mediana de cada frecuencia y restar este valor. De esta manera se mejora la visibilidad de las ráfagas solares, como se ilustra en la Figura 4.

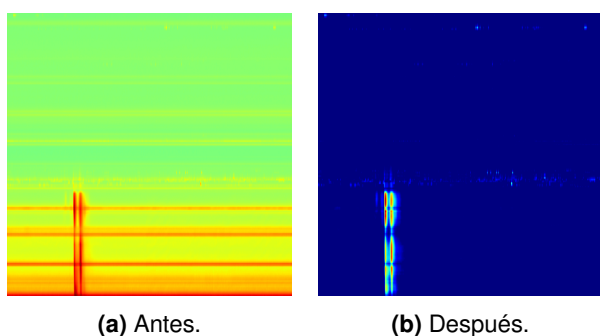


Figura 4: Pre-procesamiento de un espectrograma. **Fuente:** Elaboración propia.

La base de datos creada consta de 2152 datos, de los cuales 1722 se destinaron para entrenamiento y validación, y 430 se reservaron para pruebas. Se consideraron dos clases (SRB y NO SRB), asegurando una representación balanceada.

5.1.1. Aumento de datos

Las estrategias aplicadas fueron:

- A- Ruido Gaussiano
- B- Translación

La Figura 5 muestra un ejemplo de aumento de datos a partir de una imagen de ráfaga solar.




Figura 5: Aplicando translación como aumento de datos en una imagen con ráfaga solar. **Fuente:** Elaboración propia.

5.2. Comparación de modelos

Para el diseño del modelo, se exploraron el método estadístico y dos arquitecturas basadas en redes convolucionales. Esta sección presenta los resultados obtenidos, realiza una comparación entre ellos, selecciona el mejor modelo y lleva a cabo una evaluación de su desempeño ante nuevos datos.

5.2.1. Modelo por el Método Estadístico

El método estadístico se basa en la propiedad de que la intensidad de los píxeles debería aumentar notablemente cerca del momento del evento. Si se considera la curva de promedios de la intensidad sobre el eje del tiempo, los valores se disparan al momento que se observa una ráfaga. En Matemática, esto se traduce en la determinación de los parámetros de promedio y desviación estándar (σ) de los valores de intensidad en cada instante de tiempo. Se consideraron como parámetros de detección de ráfagas: el promedio de intensidad y el umbral que consiste en el promedio más cinco veces la desviación estándar.

Al evaluar este método utilizando el conjunto de imágenes, se obtuvo una exactitud general del 55.7 %. Sin embargo, al limitarse a los datos que contienen exclusivamente las clases SRB y al considerar su función como clasificador entre ráfagas fuertes y débiles, el algoritmo demostró ser altamente efectivo, logrando una precisión del 85 %.

5.2.2. Modelo con la red convolucional de VGG16

Utilizando el optimizador Adam, se evaluaron valores de Learning Rate (LR) entre 10^{-8} , 10^{-7} y 10^{-6} , ya que este hiperparámetro controla los pasos en un algoritmo de optimización.

También se consideró el "Batch Size"(BS), probando los valores de 4, 8 y 16. Este hiperparámetro podría ayudar a reducir el costo computacional.

Finalmente, el tamaño de la imagen (IS, por sus siglas en inglés) fue otro hiperparámetro que se ajustó. Los tamaños de imágenes considerados fueron de 112, 224 y 512 píxeles de lado.

Con las diferentes configuraciones se realizó una grilla de búsqueda con la arquitectura VGG16. Tras analizar todos los resultados y considerar los mejores valores de las métricas, la optimización del costo

computacional y la eficiencia en el tiempo de entrenamiento, se llega a la conclusión de que la mejor configuración para la arquitectura VGG16 es la siguiente:

- Learning Rate = 10^{-6}
- Batch Size = 4
- Tamaño de entrada de la imagen = 224 de lado.

A continuación se muestra la matriz de confusión de este modelo:

	Predicción de SRB	Predicción de NO SRB
SRB real	209	6
NO SRB real	25	190

Figura 6: Matriz de confusión del mejor modelo con VGG16. **Fuente:** Elaboración propia.

Los valores de las métricas con este modelo son los siguientes:

- Exactitud = 92.8 %
- F1-Score = 93.1 %
- Recall = 97.2 %
- Precisión = 89.3 %
- FNR = 2.8 %
- FPR = 11.6 %

5.3. Modelo con la red convolucional de AlexNet

Se empleó el mismo procedimiento de búsqueda en grilla, variando los mismos hiperparámetros. Una particularidad de esta arquitectura radica en el uso del SGD como optimizador, ya que se demostró que funciona de manera más efectiva con AlexNet.

En cuanto al Learning Rate, se probaron valores que funcionan mejor con el optimizador SGD, siendo 10^{-5} , 10^{-4} y 10^{-3} . La variación del Batch Size se mantuvo entre los valores de 4, 8 y 16. Así también, se mantuvo la variación del tamaño de la imagen de entrada en 112, 224 y 512 píxeles de lado.

Tras analizar todos los resultados y considerar los mejores valores de las métricas, la optimización del costo computacional y la eficiencia en el tiempo de entrenamiento, se llega a la conclusión de que la mejor configuración para la arquitectura AlexNet es la siguiente:

- Learning Rate = 10^{-3}
- Batch Size = 4
- Tamaño de entrada de la imagen = 512 de lado.

A continuación se muestra la matriz de confusión de este modelo:

	Predicción de SRB	Predicción de NO SRB
SRB real	199	16
NO SRB real	59	156

Figura 7: Matriz de confusión del mejor modelo con AlexNet. **Fuente:** Elaboración propia.

Los valores de las métricas con este modelo son los siguientes:

- Exactitud = 82.6 %
- F1-Score = 84.1 %
- Recall = 92.6 %
- Precisión = 77.1 %
- FNR = 7.4 %
- FPR = 27.4 %

Se realizó la Prueba K-Fold, que consiste en obtener la distribución de las variaciones en los resultados de las métricas. Esta prueba indica que la variabilidad de la exactitud con el modelo de VGG16 se sitúa entre 89 % y 93 %. Estos valores no se logran con el modelo de AlexNet, ni tampoco con el enfoque basado en el método estadístico. De esta manera, se concluye que la CNN utilizando la arquitectura VGG16 es el mejor modelo.

5.4. Inspección visual

Para casos dónde el modelo predice correctamente la presencia de SRB, se tienen altas probabilidades de acierto, desde las SRB más fuertes hasta aquellas de señal débil. Se presentan ejemplos ilustrativos en la Figura 8.




Figura 8: Predicciones de verdaderos positivos. **Fuente:** Elaboración propia.

Para la clase NO SRB, el modelo muestra resultados favorables incluso en presencia de ruido que no pudo ser sustraído, tal como se observa en la Figura 9.

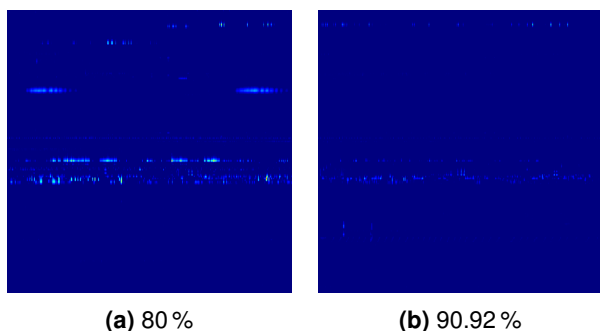


Figura 9: Predicciones de verdaderos negativos. **Fuente:** Elaboración propia.

Los falsos positivos pueden ser categorizados en dos casos distintos. En un primer caso, ciertas imágenes pueden contener eventos de SRB, pero no fueron confirmadas en la estación Humain según el reporte de e-CALLISTO. Este caso se muestra en la Figura 10.

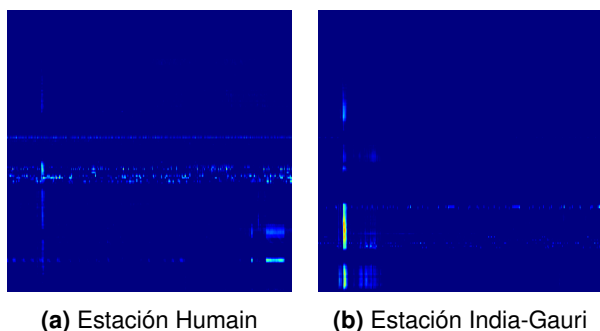


Figura 10: Primer caso de falsos positivos. **Fuente:** Elaboración propia.


En cuanto al otro caso, el modelo parece clasificar incorrectamente imágenes con niveles altos de ruido por eventos con SRB. Este problema se puede abordar ajustando el umbral de predicción, actualmente establecido en 0.5.

6. Desarrollo de la optimización de la estación

En esta sección se exponen los resultados de las mediciones y pruebas realizadas en relación con la optimización de la estación CALLISTO. En la Figura 11 se muestra la estación en su estado actual.



(a) Antena log-periódica.



(b) Toma de datos.

Figura 11: Estación actual de Paraguay. **Fuente:** Elaboración propia.

6.1. Integración de la RaspBerry Pi

Se integró la RaspBerry Pi como nuevo controlador del receptor CALLISTO. Se comenzaron a generar archivos FITS que confirmaban la adquisición de datos. Estos archivos FITS se producen en intervalos de 15 minutos durante el período de observación establecido en los archivos de configuración.

Además, se procedió a instalar los programas FTP-WatchDog y PERL-FTP. Estos programas permiten la carga de archivos en un servidor FTP conforme se generan. Su principal aplicación en conjunto con el software Callisto es facilitar el envío de los archivos FITS a los servidores correspondientes.

6.2. Análisis de la ampliación del rango espectral

En esta sección, se evalúa la viabilidad de ampliar el rango espectral mediante el uso del "Divisor Wilkinson". Se valida este componente y, a continuación, se muestran los resultados de las pruebas del Divisor Wilkinson con las antenas.

6.2.1. Divisor Wilkinson

Es un combinador de bajo costo que se encarga de combinar la antena actual junto a la antena nueva adquirida por el laboratorio. En la Figura 12 se muestra el combinador.




Figura 12: Divisor Wilkinson. **Fuente:** Elaboración propia.

Se realizaron dos pruebas, la primera consistió en medir el espectro que puede captar, para ello se requirió de dos generadores de señales de forma a combinar las señales entrantes por los dos puertos. Con señales que se encuentran en los límites del rango espectral del CALLISTO, se comprobó que el combinador puede transmitir las señales sin mucha atenuación.

La segunda prueba consiste en usar el VNA (del inglés, Vector Network Analyzer) para medir el desempeño del combinador. Se observó con una mejora en la calibración, que la atenuación es apenas de 3 dB. Además la ROE máxima fue solo de 2 para ambos puertos.

Con estas dos pruebas, se confirma que el combinador opera eficientemente en el espectro de CALLISTO, que va desde 45 MHz a 870 MHz, al recibir señales a través de cada puerto.

6.2.2. Prueba con antenas

En primer lugar, se procede a obtener el espectro de la antenna actual en conjunto con el Divisor Wilkinson. Para ello, se conecta la antenna actual a uno de los puertos del Divisor Wilkinson, mientras que el otro puerto libre se conecta a una carga de 50 Ω . La Figura 13 muestra la ROE obtenida. Se observa que se obtienen valores aceptables de la ROE, hasta aproximadamente 3 en el rango de 45 MHz a 200 MHz. De esta manera, se valida la aplicación de este combinador con la antenna actual, en el rango de 45-200 MHz.




Figura 13: ROE de la antenna actual. **Fuente:** Elaboración propia.

Luego, se procede a verificar el rango espectral de la antenna nueva en combinación con el Divisor Wilkinson. Siguiendo el mismo procedimiento mencionado previamente, se obtiene la ROE que se presenta en la Figura 14. Se observa que a partir de los 300 MHz se obtiene un valor de ROE aceptable, el cual se mantiene constante hasta el final del espectro medido. Esto indica que el rango cubierto por la antenna nueva junto con el combinador es de 300 a 870 MHz.




Figura 14: ROE de la antenna nueva. **Fuente:** Elaboración propia.

Se demostró que la ampliación del espectro puede lograrse con el combinador de bajo costo. No obstante, existe una brecha entre 200 MHz y 300 MHz, lo que no permite la combinación actual entre las antenas probadas. Se sugiere realizar una adaptación de la antenna actual, para cubrir los 100 MHz que faltan.

6.3. Selección de la nueva ubicación de la estación

En cada lugar se hizo una medición del espectro para observar la cantidad de ruido en la zona. Se usaron dos antenas, el monopolo y la log-periódica pcb,

haciendo tres mediciones por antena, sumando un total de seis mediciones por lugar. Esta rigurosidad en las mediciones fue para validar los resultados entre instrumentos, y también atendiendo que las señales de radiofrecuencia poseen una característica dinámica que requiere de varias mediciones para obtener una medida confiable.

6.3.1. Luque - ubicación actual

En la Figura 15 se muestra el espectro en Luque, presentando altos picos de ruido entre 45-250 MHz, 460-600 MHz y 760-870 MHz que van hasta los 2.1 V.




Figura 15: Espectro de radio frecuencia en CITEC.
Fuente: Elaboración propia.

6.3.2. Ayolas

Ayolas es una ciudad alejada del área urbano y dónde se ubica la FIUNA - filial de Ayolas. La Figura 16 muestra el espectro del lugar, con una característica muy plana y un pico de 1.5 V entre las frecuencias de 760-800 MHz, siendo el lugar con menos ruido de todos los medidos.




Figura 16: Espectro de radio frecuencia en Ayolas.
Fuente: Elaboración propia.

Desde el punto de vista logístico, Ayolas también es la mejor propuesta ya que se cuenta con el apoyo de la filial de Ayolas para su control.

7. Conclusión

Se realizó exitosamente un trabajo que sienta las bases para la optimización de la estación CALLISTO en Paraguay. Esta optimización implica mejoras

en la adquisición de datos, ampliación del rango espectral, recomendación de cambio de ubicación y la implementación de un sistema de detección automática de ráfagas solares. A continuación, se presentan puntualmente las conclusiones:

- Se logró con éxito la instalación del procesador de bajo consumo “Raspberry Pi” como controlador del receptor CALLISTO. Brindando mejor portabilidad y autonomía a la estación.
- Se comprobó que el combinador Divisor Wilkinson de bajo costo, puede combinar eficientemente señales de antenas, en el rango de CALLISTO, entre 45 a 870 MHz.
- Se seleccionó la ciudad de Ayolas, como la nueva ubicación de la estación. Disminuyendo sustancialmente el nivel de ruido en los datos, e integrando a la comunidad educativa de la FIUNA - filial de Ayolas en esta línea de investigación.
- Se diseñó exitosamente un sistema de detección automática de ráfagas solares basado en la CNN con la arquitectura VGG16, obteniendo una exactitud de 92.8 %.
- Se diseñó un algoritmo de detección de intensidad de ráfagas solares basado en el método estadístico, logrando una precisión de 85 %

8. Trabajos futuros

Los trabajos futuros implican la implementación de todo lo investigado, como también la optimización del estado actual. A continuación, se citan estos trabajos futuros:

- Adaptar la antena actual para aumentar su rango espectral en 100 MHz con el fin de combinarla con la antena adquirida a través del Divisor Wilkinson.
- Con el objetivo de reducir la tasa de falsos positivos, se requiere refinar la base de datos mediante una exhaustiva evaluación de eventos de SRB actualmente etiquetados erróneamente como NO SRB, incluyendo una validación cruzada con otras bases de datos confiables.
- Otro trabajo para mejorar la exactitud involucra un análisis minucioso de un nuevo umbral de predicción.
- Finalmente, el potencial de este modelo puede ampliarse para clasificar los cinco tipos distintos de SRB.

Referencias

- [1] M. Rizman, J. Johari, and F. Ahmat, "A review of solar radio burst detection using callisto," *IEEE*, 2020.
- [2] D. B. Melrose, *The emission mechanisms for solar radio bursts*. Space Sci Rev, 1980.
- [3] N. Z. M. Afandi, S. N. Hazmin, R. Umar, and A. N. Ishak, "Automated solar radio burst detection on radio spectrum: A review of techniques in image processing," *Journal of Fundamental and Applied Sciences*, p. 251, 2018.
- [4] J. Wild, "The radioheliograph and the radio astronomy programme of the culgo- ora observatory." *Proceedings of the Astronomical Society of Australia*, vol. 1, pp. 38–39, 1967.
- [5] N. Praser, A. Phakam, K. Asanok, P. Jaroenjittichai, A. Chumthong, and T. Thongmeearkom, "Callisto spectrometer for solar radio bursts monitoring in Chiang Mai," *Journal of Physics: Conference Series*, p. 2, 2019.
- [6] D. Singh, K. Sasikumar Raja, P. Subramanian, R. Ramesh, and C. Monstein, "Automated Detection of Solar Radio Bursts Using a Statistical Method," , vol. 294, no. 8, p. 112, Aug. 2019.
- [7] J. Bussons Gordo, M. Fernández Ruiz, M. Prieto Mateo, J. Alvarado Díaz, F. Chávez de la O, J. Ignacio Hidalgo, and C. Monstein, "Automatic burst detection in solar radio spectrograms using deep learning: dearc method," *Solar Physics*, vol. 298, no. 6, p. 82, Jun 2023. [Online]. Available: <https://doi.org/10.1007/s11207-023-02171-0>
- [8] B. Rino, "Automated solar radio bursts detection through machine learning," *Asterics*, pp. 5,19–20, 2019.
- [9] D. J. Matich, *Redes Neuronales: Conceptos Básicos y Aplicaciones*. Rosario, Argentina: Universidad Tecnológica Nacional, 2001, pp. 1–. [Online]. Available: <ftp://decsai.ugr.es/pub/usuarios/castro/Material-Redes-Neuronales/Libros/matich-redesneuronales.pdf>
- [10] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," *ArXiv e-prints*, Sep. 2014.
- [11] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems 25*, F. Pereira, C. J. C. Burges, L. Bottou, and K. Q. Weinberger, Eds. Curran Associates, Inc., 2012, pp. 1097–1105. [Online]. Available: <http://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf>
- [12] D. Walraven, "Understanding swr by example," *ARRL*, 2006.
- [13] (2023) e-callisto. [Online]. Available: <https://www.e-callisto.org/index.html>