

## Implementación de un Sistema Inteligente de Reconstrucción de Trazas de Muones en Experimentos de Detección de Partículas

Santiago Ferreyra<sup>1</sup>, Dr. Diego Stalder<sup>2</sup>, Dr. Jorge Molina<sup>3</sup>

<sup>1</sup>Alumno, Facultad de Ingeniería. Universidad Nacional de Asunción. San Lorenzo, Paraguay

<sup>2</sup>Orientador, Facultad de Ingeniería. Universidad Nacional de Asunción. San Lorenzo, Paraguay

<sup>3</sup>Orientador, Facultad de Ingeniería. Universidad Nacional de Asunción. San Lorenzo, Paraguay

### Palabras clave:

- CONNIE
- Muones
- Seguimiento
- GEANT4
- CNN
- YOLOv8

### Resumen

Durante la ejecución del experimento CONNIE, se desplegaron 14 sensores (dispositivos acoplados por carga) en las proximidades del reactor nuclear Angra dos Reis, Río de Janeiro, Brasil. El objetivo principal es medir las interacciones de los neutrinos a través de retrocesos de núcleos atómicos. A lo largo de los años, estos sensores han registrado imágenes de partículas, destacándose los muones como componente significativo del ruido, provenientes del impacto de rayos cósmicos en la atmósfera. El objetivo de este trabajo era desarrollar un sistema inteligente para la reconstrucción de las trayectorias de los muones a través de los sensores. Para lograr este propósito, se empleó un algoritmo, calibrado mediante imágenes sintéticas generadas por GEANT4, capaz de predecir y determinar las trayectorias de los muones basado en las características de los impactos determinados en los detectores. Además, fue implementado un modelo basado en Redes Neuronales Convolucionales (YOLOv8), entrenado para identificar y clasificar eventos muónicos.

### Keywords

- CONNIE
- Muons
- Tracking
- GEANT4
- CNN
- YOLOv8

### Abstract

During the execution of the CONNIE experiment, 14 sensors (charge-coupled devices) were deployed in the vicinity of the Angra dos Reis nuclear reactor, Rio de Janeiro, Brazil. The main objective is to measure neutrino interactions through recoils of atomic nuclei. Over the years, these sensors have recorded images of particles, with muons standing out as a significant component of the noise, originating from cosmic ray impacts in the atmosphere. The aim of this work was to develop an intelligent system for reconstructing muon trajectories through the sensors. To achieve this purpose, an algorithm calibrated using synthetic images generated by GEANT4 was employed, capable of predicting and determining muon trajectories based on the characteristics of impacts determined in the detectors. Additionally, a model based on Convolutional Neural Networks (YOLOv8) was implemented, trained to identify and classify muonic events.

### 1. Introducción

En el ámbito de los experimentos de física de partículas, lograr una reconstrucción precisa de las trayectorias de las partículas, conocido como *seguimiento*, sirve como fundamento crucial para desentrañar las características esenciales del reino subatómico.

Ejemplificado por hitos como los desafíos TrackML, Bosón de Higgs y Flavour of Physics [1, 2] en el aprendizaje automático para la física de partículas, resuenan la importancia de rastrear las trayectorias de las partículas.

La reconstrucción de trayectorias implica funda-

mentalmente encontrar los eventos vinculados a una partícula cuando atraviesa varios detectores, planteando un desafío combinatorio [1]. En este estudio, nuestro objetivo es identificar trayectorias de las partículas que atraviesan los detectores del experimento CONNIE (Coherent Neutrino-Nucleus Interaction Experiment) [3].

El principal reto que enfrentan los experimentos de búsqueda es entender y poner bajo control las señales de ruido en el detector (*background*). Estas señales se refieren a todas aquellas fuentes de ruido que pueden generar señales similares a las que se están buscando [4]. Las que se asocian a los rayos cósmicos son en su mayoría debido a los muones, partículas altamente penetrantes que se detectan en la Tierra como resultado de interacciones de partículas en la atmósfera terrestre con los rayos cósmicos de altas energías [5].

Las imágenes capturadas por los sensores abarcan una variedad de características, incluyendo patrones inducidos por electrones, puntos distintivos de partículas alfa, gamma, rastros de muones tanto verticales como regulares [6]. Por lo tanto, un algoritmo de seguimiento robusto es esencial para la identificación precisa y la asociación de las características inducidas por las partículas de interés. Para abordar esta complejidad, se llevan a cabo simulaciones de las interacciones de los muones con los detectores CONNIE mediante el uso de herramientas especializadas en la simulación del paso de partículas a través de la materia, como GEANT4.

De manera análoga, se plantea desarrollar un modelo mediante YOLOv8 [7] capaz de clasificar las diversas trazas identificadas en los dispositivos de carga acoplada. Este modelo, basado en redes neuronales convolucionales, destaca por su capacidad para discernir las trazas muónicas entre la multitud de eventos registrados en el experimento. Esta arquitectura es conocida por su rapidez en procesamiento y entrenamiento, lo que la hace ideal para analizar grandes cantidades de datos. Al implementar esta técnica, se pretende mejorar la precisión de los resultados logrados en trabajos experimentales anteriores [8].

La integración conjunta de ambas instancias, es decir, un algoritmo calibrado mediante imágenes sintéticas y el modelo entrenado con imágenes etiquetadas del experimento, permite realizar un seguimiento preciso de las trayectorias a lo largo de todos los dispositivos. Esta implementación culmina en un sistema inteligente que pretende abordar de manera eficaz las complejas interacciones muónicas. Esta capacidad proporciona la flexibilidad necesaria para extender los límites de la investigación, permitiendo la aplicación exitosa en futuros experimentos que demanden un análisis detallado de este tipo de interacciones.

## 1.1. Objetivos

### 1.1.1. Principal

Desarrollar un sistema de reconstrucción de trazas de muones para experimentos físicos compuestos de varios detectores, a través de métodos heurísticos con la capacidad de reconocer y seguir las trayectorias de los muones a fin de eliminar el ruido en los detectores.

### 1.1.2. Específicos

- Investigar y seleccionar métodos heurísticos adecuados para la reconstrucción de trazas de muones.
- Generar datos sintéticos que simulen las trazas de muones y su interacción con los detectores, incorporando diferentes escenarios para evaluar la robustez y precisión del sistema de reconstrucción propuesto.
- Evaluar modelos de inteligencia artificial que permitan la detección, clasificación y segmentación de las trazas muónicas entre los eventos determinados en los detectores.
- Implementar el sistema de reconstrucción de trazas de muones en datos reales recopilados por experimentos físicos de detección de partículas.
- Validar los algoritmos de reconstrucción en los muones identificados por los modelos con resultados de trazas reales previamente analizadas asegurando la consistencia y precisión en la identificación de las partículas.

## 2. Marco Teórico

El primer paso es la comprensión de los aspectos involucrados en los experimentos físicos y las interacciones de las partículas, así como las redes neuronales convolucionales y las métricas de evaluación.

### 2.1. Experimento CONNIE

El experimento CONNIE (acrónimo de Coherent Neutrino-Nucleus Interaction Experiment) utiliza dispositivos de carga acoplada CCD (Charge-Coupled Device) completamente agotados y de bajo nivel de ruido con el propósito específico de medir retrocesos de baja energía derivados de la dispersión elástica coherente de neutrinos-núcleos (CEvNS). Estos retrocesos se buscan para la detección de interacciones de antineutrinos producidos en el reactor nuclear de Angra 2, ubicado en la planta Almirante Álvaro Alberto en Angra dos Reis, Brasil [3].

El experimento está ubicado dentro de un contenedor a 30 m fuera del edificio del reactor principal. El recipiente de vacío se instala dentro de un escudo de plomo y polietileno contra la radiación. El plomo actúa como un eficaz escudo para los rayos gamma, mientras que el polietileno se revela como una barrera efectiva contra los neutrones generados por la interacción con muones cósmicos [9].

## 2.2. Dispositivos de Carga Acoplada

Dispositivos que destacan por su alta eficiencia de detección, bajo nivel de ruido, buena resolución espacial y baja corriente oscura, los vuelve idóneos para medir deposiciones de baja energía siendo el experimento CONNIE pionero en la aplicación de CCDs para la búsqueda de CEvNS con neutrinos provenientes de reactores.

Fabricados con silicio de alta resistividad ( $10\text{-}20\text{ k}\Omega\cdot\text{cm}$ ), le permite su funcionamiento en agotamiento total con voltajes de sustrato moderados. Los mismos están montados horizontalmente en una caja de cobre, que se mantiene dentro de un recipiente de vacío de cobre ( $10\text{-}7\text{ torr}$ ). Para reducir la corriente oscura generada térmicamente en el silicio, los sensores se enfrían a temperaturas inferiores a  $100\text{ K}$  mediante un enfriador criogénico de helio de ciclo cerrado.

Su división en píxeles, cada uno de ellos albergando un potencial electrostático, acumularán los huecos de los electrones generados como resultado de las interacciones con las partículas. Las mismas, al impactar en el detector durante el tiempo de exposición, serán posteriormente leídas píxel por píxel. La información resultante se almacenará en registros seriales acoplados a los bordes del CCD, con el propósito de generar imágenes.

## 2.3. Muones

Con el objetivo de suprimir los eventos relacionados con la radioactividad natural, se diseñan los blindajes utilizados en el experimento. Sin embargo, estos no logran detener las partículas altamente energéticas producidas en la estratosfera, como es el caso de los muones. Debido a su baja interacción electromagnética, son capaces de atravesar la roca a varias decenas de metros antes de desintegrarse. A pesar de que su flujo no es muy alto, alrededor de un muón por centímetro cuadrado por minuto al nivel del mar, continuamente llegan a nosotros, estando incluso presentes en los experimentos.

Debido a su elevada masa, al atravesar el escudo de protección, los muones excitan notables cantidades de electrones en los píxeles de los CCDs. Las trazas dejadas por los muones en sí mismas no representan un problema. Sin embargo, la complejidad aumenta cuando estos interactúan con los diversos componentes del blindaje del detector, generando otras partículas de menor energía que pueden confundirse con las señales producidas por los neutrinos. Por este motivo, resulta fundamental identificar las señales originadas por los diferentes tipos de partículas que conforman el fondo, ya sean naturales o producidas por rayos cósmicos, con el fin de separarlas de los datos generados por los neutrinos.

## 2.4. GEANT4

GEANT4 es un conjunto de herramientas para simular el paso de partículas a través de la materia. Ha

sido diseñado y construido para exponer los modelos físicos utilizados, manejar geometrías complejas y permitir su fácil adaptación para un uso óptimo en diferentes conjuntos de aplicaciones. La aplicación de GEANT4 se ha vuelto esencial en el área de las detecciones y estudios de interacciones de partículas.

## 2.5. Algoritmos de Seguimiento de Muones

Los algoritmos de seguimiento de muones constituyen un conjunto de procedimientos computacionales diseñados con el propósito de reconstruir las trayectorias de los muones dentro de un detector de partículas. Experimentos para el seguimiento de muones se han realizado mediante el uso de fotomultiplicadores de silicio para caracterizar propiedades de fotosensores (SiPM) [10], en el Observatorio Subterráneo de Neutrinos de Jiangmen (JUNO) en un detector de centelleo líquido para la exclusión efectiva de los fondos cosmológicos [11], y como tomografía de núcleos de los reactores nucleares de Fukushima Daiichi [12].

## 2.6. Inteligencia Artificial

La esencia de la inteligencia es el principio de adaptarse al entorno mientras se trabaja con conocimientos y recursos insuficientes. En los últimos años, los algoritmos basados en áreas de la inteligencia artificial han alcanzado mejoras significativas como herramientas de alta eficiencia para la resolución de problemas de gran envergadura, en la cual se dispone una enorme cantidad de datos. La principal disciplina de interés radica en la capacidad de realizar operaciones con el fin de reducir tiempos de ejecución por sobre la intervención humana, dando como resultado la posibilidad de tener un impacto en diversas áreas de aplicaciones prácticas.

## 2.7. Aprendizaje Automático

El aprendizaje automático (Machine Learning) es una categoría de inteligencia artificial que permite a las computadoras pensar y aprender por sí mismas. Se trata de hacer que las computadoras modifiquen sus acciones para lograr una mayor precisión, donde la misma se mide en términos de cuántas veces las acciones elegidas resultan correctas [13].

El enfoque de aprendizaje automático sustituye el paso de adquirir conocimiento del dominio por la tarea potencialmente más fácil de recopilar una cantidad suficientemente grande de ejemplos de comportamiento deseado para el algoritmo de interés. Estos ejemplos constituyen el conjunto de entrenamiento mediante el cual se espera que el algoritmo aprenda.

## 2.8. Aprendizaje Profundo

El aprendizaje profundo representa una disciplina distintiva dentro del amplio campo del aprendizaje automático. Su enfoque central radica en la capacidad de aprender parámetros a lo largo de capas su-


cesivas de representaciones, evolucionando hacia niveles de abstracción cada vez más pronunciados. El mismo, compuesto de múltiples capas de procesamiento, representa un acercamiento íntimo al modo de funcionamiento del sistema nervioso humano, ya que el encéfalo humano está compuesto de núcleos y áreas diferenciadas para que las redes neuronales estén especializadas, formando así una arquitectura de gran complejidad.

### 2.8.1. Neuronas Biológicas

La compleja red de neuronas en el cerebro humano, conectadas a través de sinapsis, forma la base del procesamiento de información y la capacidad de autoaprendizaje. Tal interconexión permite la transmisión de señales eléctricas o químicas, facilitando la comunicación entre células nerviosas. Aunque los modelos artificiales actuales están lejos de replicar completamente la complejidad del cerebro humano, la investigación en este campo avanza constantemente.

### 2.8.2. Neuronas Artificiales

Es así que, del mismo modo en que cálculos bastante complejos se pueden realizar con estructuras tan simples como las neuronas, para casos computacionales existe una pieza individual básica definida como la neurona artificial que emula el comportamiento de una biológica. Se describe el procedimiento del algoritmo matemático de una neurona en la Figura 1.



**Figura 1:** Neurona Artificial: Emulación del potencial humano. **Fuente:** [14].

La operación matemática de la salida de esta neurona para entradas dadas viene dada por:


$$z = [W_1 \quad W_2] \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + b$$

donde  $x_1$  y  $x_2$  son las entradas de las neuronas anteriores,  $W_1$  y  $W_2$  son los pesos,  $b$  es el sesgo (bias) de esta neurona, por lo que puede denominarse  $z$  al umbral de activación de la neurona. Así, se busca emular las interacciones de las dendritas de las neuronas humanas [14], donde la sinapsis es similar a la activación que se transmite a la siguiente neurona como entradas.

## 2.9. Redes Neuronales Artificiales

Las redes neuronales artificiales (ANN, del inglés: Artificial Neural Networks) son sistemas de pro-


cesamiento computacional fuertemente inspirados en la forma en que operan los sistemas nerviosos biológicos. Las ANN se componen principalmente de una gran cantidad de neuronas artificiales interconectadas cuyo trabajo se entrelaza de forma distribuida para aprender colectivamente de la entrada con el fin de optimizar su salida final [15]. La estructura básica de una ANN se puede modelar como se muestra en la Figura 2.



**Figura 2:** Redes Neuronales Artificiales: Una red compuesta por una capa de entrada la cual distribuye la información a las capas ocultas y ponderan un resultado final a la capa de salida. **Fuente:** [15].

## 2.10. Redes Neuronales Convolucionales

Las redes neuronales convolucionales (CNN, del inglés: Convolutional Neural Networks) son análogas a las ANN tradicionales en que están compuestas de neuronas que se auto-optimizan mediante el aprendizaje, siendo las mismas mas enfocadas al análisis de datos en cuadrícula, como imágenes. Cada neurona seguirá recibiendo una entrada y realizará una operación (como un producto escalar seguido de una función no lineal), desde los vectores de imagen sin procesar de entrada hasta la salida final de la puntuación de la clase, toda la red seguirá expresando una única función de puntuación perceptiva [15] (Figura 3).



**Figura 3:** Redes Neuronales Convolucionales: Una arquitectura CNN simple. **Fuente:** [16].

## 2.11. Visión computacional

La visión computacional trata de describir el mundo que vemos en una o más imágenes y construir sus propiedades, tales como la forma, iluminación, distribución de color y otros mediante un conjunto de procesos destinados a realizar el análisis de imágenes:


captación de imágenes, memorización de la información, procesamiento e interpretación de los resultados.

### 2.11.1. Clasificación de Objetos

La clasificación de imágenes es una tarea fundamental para la cual un anotador atribuye una etiqueta a una pieza de datos completa. El desafío fundamental de una técnica de clasificación de imágenes radica en la extracción de características. Al utilizar un conjunto de datos etiquetados con sus categorías correspondientes, se entrena un modelo para lograr este resultado. Después de eso, un modelo puede predecir la etiqueta o categoría de imágenes nuevas y no vistas.

### 2.11.2. Detección de Objetos


Mientras que la clasificación de imágenes se centra en asignar una única etiqueta a una imagen completa, los modelos de detección de objetos van un paso más allá al reconocer y señalar las posiciones de numerosos objetos dentro de una imagen, como se observa en la Figura 4.



**Figura 4:** Detección de Objetos: En la que se pueden observar tres clases diferentes detectadas. **Fuente:** [7].

### 2.11.3. Segmentación de Objetos

Mientras que la detección de objetos encuentra cuadros delimitadores alrededor de los objetos y los clasifica. La segmentación de imágenes es una función que toma entradas de imágenes y produce una salida que corresponde a una máscara de píxeles que proporciona la forma del objeto o una matriz con diversos elementos que especifican la clase u instancia de objeto a la que pertenece cada píxel, como se observa en la Figura 5.



**Figura 5:** Segmentación de Objetos: En la que se pueden observar las clases segmentadas. **Fuente:** [7].

## 2.12. Arquitecturas de detección de objetos

Los arquitecturas de aprendizaje profundo para la detección visual de objetos se dividen principalmente en dos modelos: los de dos etapas y los de una etapa. Los modelos de dos etapas generan una caja preseleccionada, conocida como propuesta de región (RP, del inglés, Region Proposal), que potencialmente contiene un objeto a detectar. Estos modelos luego clasifican las muestras dadas utilizando redes neuronales convolucionales. En contraste, los modelos de detección de objetos de una etapa evitan el uso de RP, extrayendo directamente características visuales para predecir la clase y ubicación del objeto.

### 2.13. YOLO

Entre los diferentes algoritmos de detección de objetos, el marco YOLO se ha destacado por su notable equilibrio entre velocidad y precisión, permitiendo la identificación rápida y confiable de objetos en imágenes. El nombre *YOLO* significa "You Only Look Once" (Solo Mira Una Vez), haciendo referencia al hecho de que podía realizar la tarea de detección con un solo paso de la red.

### 2.14. YOLOv8

YOLOv8 es un modelo de vanguardia (SOTA, state-of-the-art) que se basa en el éxito de versiones anteriores e introduce nuevas características y mejoras para aumentar aún más el rendimiento y la flexibilidad respecto a sus predecesoras. YOLOv8 está diseñado para ser rápido, preciso y fácil de usar, gracias a que es capaz de incorporar diferentes mapas de características a diferentes escalas para aprender sobre las formas y texturas de los objetos. Lanzado en enero de 2023 por Ultralytics, admitiendo múltiples tareas de visión, como detección de objetos, segmentación, estimación de pose, seguimiento, y clasificación, proporciona cinco versiones escaladas:

- YOLOv8n (nano)
- YOLOv8s (pequeño)
- YOLOv8m (mediano)
- YOLOv8l (grande)
- YOLOv8x (extra grande)


### 2.15. Limitaciones

El algoritmo YOLO tiene algunas limitaciones, como la dificultad para lidiar con objetos pequeños, la incapacidad para realizar clasificaciones detalladas, y la imposibilidad de definir un único píxel bajo dos clases diferentes.

## 3. Metodología del Algoritmo

Se detalla la implementación del algoritmo capaz de predecir los desplazamientos de las partículas entre detectores de modo a determinar las trayectorias de las partículas a través de los mismo (ver Figura 6).





**Figura 6:** Fuente: Elaboración propia.

### 3.1. Imágenes Sintéticas

En el contexto de GEANT4, los muones se simulan de tal forma que es posible capturar y registrar la deposición de energía a cada paso por los detectores en su trayectoria formando las imágenes de la misma manera que el experimento CONNIE. La configuración utilizada para el lanzamiento de las partículas esta basada en la dependencia del flujo de muones con el ángulo cenital basado experimentalmente en el coseno cuadrado:

$$I(\vartheta) = I_0 \cos^2(\vartheta); \quad (1)$$

### 3.2. Extracción de características

Todas las características fueron evaluadas con el objetivo de identificar patrones de linealidad con el desplazamiento de la partícula, posibilitando así la asociación precisa de los impactos con sus respectivas trayectorias. De las características consideradas, el tamaño de la imagen caracteriza las dimensiones del área de impacto. Se calcula como el intervalo de coordenadas que abarca un evento:

$$s_x = \max(x_i) - \min(x_i), \quad s_y = \max(y_i) - \min(y_i) \quad (2)$$

donde  $i$  son las posiciones de impacto a lo largo de los ejes. El centroide se determina mediante el promedio de las posiciones asociadas a un impacto específico estimando la ubicación del impacto y se calcula de la siguiente manera:

$$c_x = \frac{1}{N} \sum_{i=1}^N x_i, \quad c_y = \frac{1}{N} \sum_{i=1}^N y_i \quad (3)$$

donde  $i$  denota las posiciones de impacto del muón en el CCD, y  $N$  representa el número de impactos asociados a cada impacto. Mientras que la asimetría, mide lo cerca o lejos que está el centroide del centro de la ventana. Esta relación se determina de la siguiente manera con respecto al centroide:

$$a_x = c_x - \frac{1}{2}(x_{\max} + x_{\min}), \quad a_y = c_y - \frac{1}{2}(y_{\max} + y_{\min}) \quad (4)$$


la evaluación de la forma y distribución del impacto dentro de la ventana se basa en gran medida en el concepto de asimetría.

### 3.3. Etapas del Algoritmo

El algoritmo se bifurca en dos etapas: La etapa inicial que predice la posición del impacto de un muon en el siguiente detector mediante regresión lineal, y la etapa final que implica la asociación de los eventos a una única trayectoria correspondiente a una partícula basado en las métricas de similitud en una ventana de búsqueda.

#### 3.3.1. Predicción mediante regresión lineal

Esta etapa consiste en predecir el desplazamiento  $D = \{d_x, d_y\}$  de un impacto, de modo que el centroide de impacto es estimado el siguiente detector  $E = \{c_x + d_x, c_y + d_y\}$  teniendo en cuenta las características extraídas en la sección anterior. Como se muestra en la Figura.7, tanto el tamaño del evento como la asimetría demuestran una correlación lineal con el desplazamiento. Para estimar los parámetros de la regresión lineal, dividimos las regiones de interés en tres zonas:  $Z_1$ ,  $Z_2$ , y  $Z_3$ .



**Figura 7:** Zonas de Linealidad. Fuente: Elaboración propia.

Estas zonas están determinadas por tres umbrales:  $T_1$ ,  $T_2$ , y  $T_3$ . En el algoritmo, los sucesos con desplazamientos superiores a el umbral especificado  $T_1$  se someten a evaluación mediante una regresión lineal basada en la ecuación del tamaño del evento (5). Por el contrario, los sucesos con desplazamientos inferiores a ( $T_1$ ) se evalúan en función de su asimetría mediante la ecuación (6).

#### 3.3.2. Resultados de la regresión Lineal

La evaluación de la regresión lineal de los datos determina las ecuaciones de la predicción de la posición tal que:

$$E_k = s_k \cdot 7,681 - 572,638, \text{ si } T_1 \geq s_k \text{ para } k \in \{x, y\} \quad (5)$$

$$E_k = a_k \cdot 15,288 - 4,616, \text{ si } T_1 < s_k \text{ para } k \in \{x, y\} \quad (6)$$

Aquí  $E_x$  y  $E_y$  significan la estimación del centroide del impacto en el detector posterior, mientras que  $m_{size}$ ,  $b_{size}$ ,  $m_{asym}$ , y  $b_{asym}$  son parámetros obtenidos mediante la regresión de los datos.

#### 3.3.3. Umbrales de Búsqueda.

Para optimizar la selección de umbrales, presentamos una evaluación detallada en la Tabla 1. Esta tabla explora sistemáticamente diversos conjuntos de parámetros para identificar la combinación que produce la mayor eficiencia. La ultima fila en la tabla indica

la configuración que brinda la mayor eficiencia, definida como los eventos etiquetados correctamente, alcanzando un valor 98.92 %.


**Tabla 1:** Combinaciones de umbrales y eficiencias

$T_1$	$T_2$	$T_3$	Eficiencia
169	25	300	97.50
172			97.567
175			97.229
172	35	300	98.648
	45		98.716
	55		98.716
172	45	400	98.716
		600	98.918
		800	98.716
172	45	600	98.918

**Fuente:** Elaboración propia.


### 3.3.4. Asociación de los Eventos en una Ventana de Búsqueda

El paso inicial consiste en definir ventanas de búsquedas ( $W_1, W_2$ ) para localizar los posibles impactos en el próximo detector, en la que pueden situarse múltiples candidatos (Figura 8).



**Figura 8:** Ventanas de búsqueda. **Fuente:** Elaboración propia.

Para iniciar la búsqueda, se comienza por seleccionar un evento  $p$ , en un  $CCD_i$ , donde  $i \in 1, 2, \dots, 10$ , denotado por  $E^{p, CCD_i}$ . Mediante la regresión lineal se busca determinar la estimación del impacto en el  $CCD_{i+1}$  posterior. Se establece  $W_1$  para identificar todos los eventos candidatos que estén limitados por él. Tras una coincidencia entre dos sucesos en CCD contiguos se utiliza ( $W_2$ ), como se observa en la Figura. 8. Posteriormente, se usan métricas de similitud para discernir y seleccionar al evento apropiado a la trayectoria (Figura 9).



**Figura 9:** Búsqueda de Impactos. **Fuente:** Elaboración propia.

### 3.4. Ajuste de Ventanas

La Tabla 2 ilustra la evaluación de varios conjuntos en términos del tamaño de ventana ( $W_1$ ) y lo mismo para ( $W_2$ ) en la Tabla 3.

**Tabla 2:** Evaluación de ( $W_1$ ).

Set	$W_1$					
	300	400	500	600	700	800
Eficiencia	96.621	98.243	98.378	98.581	98.513	98.243
Fallos	50	26	24	21	22	26

**Fuente:** Elaboración propia.

**Tabla 3:** Evaluación de ( $W_2$ ).

Set	$W_2$					
	100	150	200	250	300	350
Eficiencia	96.554	98.243	98.513	98.581	98.581	98.243
Errores	51	26	22	21	21	26

**Fuente:** Elaboración propia.

### 3.5. Similitud

Para evaluar la similitud entre el suceso original proyectado, que corresponde al mismo evento en la posición de la estimación predicha por el algoritmo, denominado  $E^{p, CCD_{i+1}}$ , y cada suceso candidato  $E^{j, CCD_{i+1}}$  dentro de la ventana de búsqueda en  $CCD_{i+1}$ , se utiliza la norma  $L_2$  que se expresa como:

$$\text{Similitud}(E^{p, CCD_{i+1}}, E^{j, CCD_{i+1}}) = M_1 + M_2 + M_3 \quad (7)$$

$$M_1 = \|S^{p, CCD_{i+1}} - S^{j, CCD_{i+1}}\|_2$$

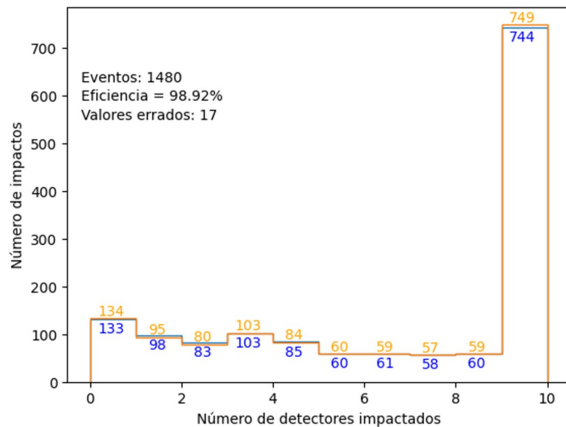
$$M_2 = \|C^{p, CCD_{i+1}} - C^{j, CCD_{i+1}}\|_2 \quad (8)$$

$$M_3 = \|A^{p, CCD_{i+1}} - A^{j, CCD_{i+1}}\|_2$$

Así, se asignan todos los eventos identificados por la búsqueda vinculada a una partícula con un número de evento concreto. Posteriormente, se procede a la evaluación de un impacto posterior, realizando búsquedas entre los que aún no han sido asignados. Mediante este proceso iterativo, se visitan todos los sucesos y se asocian a un suceso específico al culminar el procedimiento.

### 3.6. Eficiencia del Algoritmo

La Figura. 10 destaca la eficiencia del algoritmo al asociar de manera consistente y precisa eventos de impacto en una variedad de CCDs. Las eficiencias observadas, para el mejor de los casos, alcanza un valor de efectividad de 98.92% equivalente a únicamente 17 eventos que no han sido catalogados correctamente sobre 1480 que ocurrieron.



**Figura 10:** Eficiencia. Fuente: Elaboración Propia.

### 3.7. Digitalización

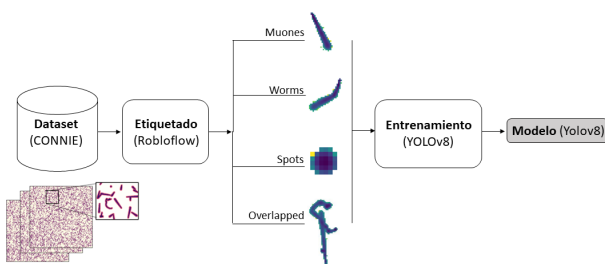
La digitalización implica la conversión de información analógica o continua en una representación digital discreta, expresada mediante valores numéricos. En el experimento CONNIE, donde cada sensor CCD se configura como una matriz de 4300x4300 píxeles, cada píxel tiene una longitud de  $15 \mu\text{m} \times 15 \mu\text{m}$ , la implementación del algoritmo en imágenes reales debe regir las ecuaciones como se describen :

$$E_k = s_k \cdot 7,681 - 38,175, \text{ si } T_1 \geq s_k \text{ para } k \in \{x, y\} \quad (9)$$

$$E_k = a_k \cdot 15,288 - 0,307, \text{ si } T_1 < s_k \text{ para } k \in \{x, y\} \quad (10)$$

## 4. Metodología del Modelo

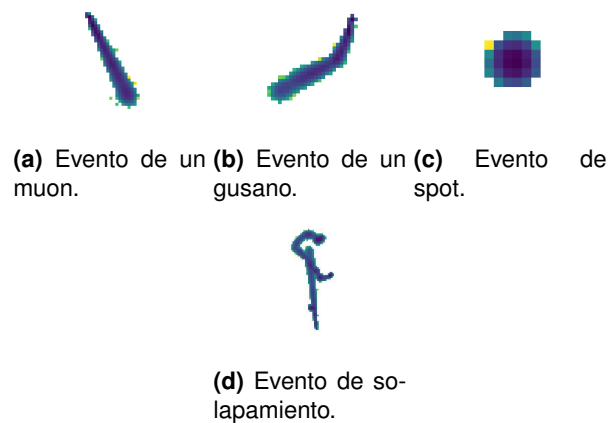
En este capítulo se detalla la implementación del modelo de entrenamiento mediante YOLOv8 para la detección, clasificación y segmentación de los eventos de modo a determinar aquellas trazas muónicas que construyen las trayectorias de los mismo.



**Figura 11:** Metodología del Modelo. Fuente: Elaboración propia.

### 4.1. Etiquetado de Imágenes.

En el marco del entrenamiento se emplearon dos conjuntos de datos catalogados elaborados por el Ingeniero Javier Bernal y los Ingenieros Carlos Silva y Karina Aquino[8]. Dichos conjuntos de datos comprenden un total de 1238 imágenes de eventos, distribuidas entre 801 correspondientes al primer conjunto y 437 al segundo.



**Figura 12:** Ejemplos de la clasificación. Fuente: Elaboración propia.

La clasificación del modelo de seguimiento de muones comprende aquellas de interés para el trabajo basado en:

- Muones.
- Gusanos (Worms).
- Spots.
- Eventos Solapados (Overlapped).

Tras el análisis del etiquetado de todas las imágenes, la distribución de las etiquetas correspondiente a las clases individuales y solapadas puede verse en la Tabla 4.

**Tabla 4:** Distribución de etiquetas en el conjunto de datos.

Clase	Cantidad
<b>Eventos Individuales</b>	<b>802</b>
Muones	653
Spots	69
Gusanos	80
<b>Eventos Solapados</b>	<b>436</b>
Muones	148
Gusanos	76
Muones con gusanos	212
<b>Eventos Totales</b>	<b>1238</b>

Fuente: Elaboración propia.

### 4.2. Segmentación de Instancias


Tras el etiquetado correspondiente, el conjunto de datos fue exportado para el entrenamiento mediante



YOLOv8, en el cual se han re-entrenado 5 modelos de segmentación disponibles pre-entrenados en el conjunto de datos COCO el cual posee sus propios pesos y es capaz de adaptarse a las nuevas etiquetas. Donde YOLOv8n es el más pequeño y rápido, mientras que YOLOv8x es el más preciso y lento entre los otros modelos. La elección del modelo adecuado es un equilibrio entre la optimización de la precisión y la eficiencia en términos de recursos computacionales.

#### 4.3. Resultados del entrenamiento.

La precisión (mAP) de las cajas mide la exactitud de las cajas delimitadoras predichas en comparación con las cajas reales utilizando IoU (Intersección sobre Unión) como métrica, mientras que la precisión (mAP) de las máscaras evalúa la concordancia entre las máscaras de segmentación predichas y las máscaras reales en la clasificación de objetos por píxeles.



**Figura 13:** Métricas mAP. **Fuente:** Elaboración Propia.

Las imágenes del conjunto de datos se ajustaron al criterio de entrada de YOLOv8, convirtiendo todas a imágenes de 640x640 y los resultados se observan en la Tabla 5.

**Tabla 5:** Comparación de modelos YOLOv8 con segmentación.

Modelo	mAP (box 50-95)	mAP (mask 50-95)	Params (M)
YOLOv8-n	0.698	0.625	3.26
YOLOv8-s	0.727	0.661	11.79
YOLOv8-m	0.731	0.671	27.24
YOLOv8-l	0.74	0.674	45.93
YOLOv8-x	0.746	0.679	71.72

**Fuente:** Elaboración propia.


Por criterios de selección para asegurar el mejor funcionamiento en la segmentación de instancias y respecto a la cantidad de parámetros y tiempos de ejecución se ha seleccionado al:

#### Modelo YOLOv8l-seg.

##### 4.3.1. Funciones de Costo.

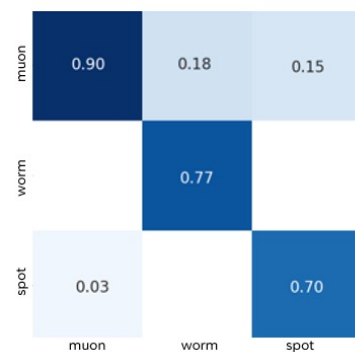
YOLOv8 utiliza diversas funciones de pérdida para mejorar la predicción, para el entrenamiento podemos observarlo en la Figura 14 las cuatro utilizadas en nuestro conjunto de imágenes. En general, se espera que todas las funciones de pérdida disminuyan

a medida que el modelo se entrena y aprende. Un descenso abrupto seguido de una estabilización en un valor bajo para cada función de pérdida sugiere un entrenamiento exitoso del modelo (Figura. 14).



**Figura 14:** Funciones de costo. **Fuente:** Elaboración Propia.


La Figura 15 muestra la eficiencia enorme respecto a las clases de interés. De modo se determinan con certeza para la clase “muon” una tasa de clasificación correcta del 90 %, mientras que tanto para “gusanos” y “spots” superan una tasa del 70 %.



**Figura 15:** Matriz de Confusión Normalizada. **Fuente:** Elaboración Propia.


##### 4.3.2. Evaluación Final

La Figura 16 ilustra una colección de predicciones por parte del modelo elegido.



**Figura 16:** Ejemplo de una instancia correcta (izquierda) e incorrecta (derecha). **Fuente:** Elaboración Propia.


Es destacable la problemática asociada con los eventos solapados, donde la máscara de segmentación en numerosas ocasiones no logra identificar de manera precisa los eventos, lo que nos conduce a optar por la selección de muones individuales. (ver Figura 17).



**Figura 17:** Ejemplo de una instancia incorrecta de la segmentación con el modelo seleccionado. **Fuente:** Elaboración Propia.

## 5. Metodología de la Implementación

En esta sección, se presentan y analizan los resultados del modelo entrenado previamente sobre los eventos detectados en los detectores CCD, así como la implementación del algoritmo de seguimiento de muones.



**Figura 18:** Metodología de la Implementación. **Fuente:** Elaboración propia.

### 5.1. Detectores

La base del conjunto de datos se originó a partir de una ejecución del experimento CONNIE. Los datos utilizados para esta evaluación abarcan ejecuciones comprendidas entre el 28 de mayo (14:40:07 UTC) y el 5 de junio de 2018 (20:12:49 UTC). Donde los eventos vienen determinados por información respecto a los píxeles, los niveles energéticos y los detectores correspondientes. A fines prácticos del seguimiento de los muones a través de los detectores, se puede realizar manera continua a través de los **OHDU = 2, 3, 8, 9**.

### 5.2. Extracción de Datos

Para la adquisición de los eventos, correspondiente a grupos de píxeles que están asociados con deposiciones de energía en los CCD, han sido considerando tres características con la intención de reducir el ruido y evitar eventos indeseados: Dimensión

mayor a cinco píxeles, píxeles de "Nivel 2z energía mínima de umbral.

### 5.3. Predicción de las Imágenes.

Tras la determinación de las características, se procede a la de implementación del modelo YOLOv8 de modo a obtener la detección de las partículas mediante un cuadro delimitador (*bounding box*), la clasificación del evento según las clases de interés y la segmentación correspondientes a los píxeles de los eventos.

### 5.4. Determinación de Eventos Muónicos

La confianza del evento corresponde a la certeza con la cual un evento es determinado como una de las clases. De modo que para rigurosidad, se ha establecido una confianza mayor al **85 %**. La primera evaluación del sistema se llevó a cabo en el **runID=3813**. En la tabla 6, se pueden observar la cantidad de eventos determinados a los CCD con un funcionamiento correcto. En total se disponen de **39.194 eventos** para la primera ejecución de los datos.

**Tabla 6:** Valores de los eventos y sus OHDU correspondientes al runID=3813.

Detector	OHDU	Eventos	Validos
1	2	3965	3536
2	3	4240	3566
3	8	4277	3632
4	9	4953	3614
6	14	4525	3632
7	4	4042	3612
9	10	4245	3633
10	13	4328	3668
12	5	4080	3663
13	7	4784	3585

**Fuente:** Elaboración propia.

Se puede observar en la tabla 7, la cantidad de eventos y las clases correspondientes y eventos no detectados correctamente (fails) determinados por el modelo determinado con YOLOv8 a través de todos los detectores. El algoritmo busca evaluar el seguimiento de las trayectorias sobre los **22.747** eventos muónicos.

**Tabla 7:** Cantidad de eventos y su clasificación correspondiente al runID=3813.

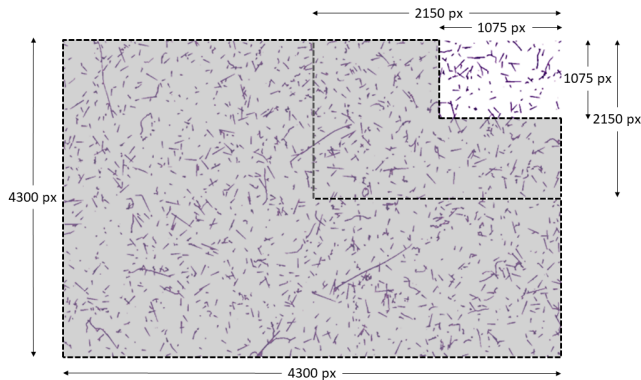
Events	Muons	Worms	Spots	Overlapped	Fails
3536	2290	427	148	536	135
3566	2253	453	154	544	162
3612	2294	424	167	576	151
3663	2318	460	173	533	179
3585	2204	436	170	596	179
3632	2326	438	177	505	186
3614	2263	446	159	557	189
3633	2265	443	186	543	196
3668	2292	475	152	543	206
3632	2242	458	186	532	214
36141	22747	4460	1672	5465	1797
100 %	62,94 %	12,34 %	4,62 %	15,12 %	4,98 %

**Fuente:** Elaboración propia.

### 5.5. Implementación de Algoritmo

Las imágenes correspondientes al experimento son dimensionalmente de 4300x4300 (píxeles), por lo que la evaluación del modelo se realiza con el fin de ir validando la eficiencia del algoritmo sobre:

1. Un octavo de la imagen (1075x1075 px).
2. Un cuarto de la imagen (2150x2150 px).
3. La totalidad de la imagen (4300x4300 px).



**Figura 19:** Configuración de búsqueda empleada.

**Fuente:** Elaboración Propia.

### 5.6. Resultados del Sistema.

Para evaluar los resultados del sistema se determinan los eventos que correspondan de manera correcta con el etiquetado realizado por el algoritmo por inspección visual. Donde define un criterio denominado “**Efectividad**” basado en los eventos VP (verdaderos positivos, aquellos etiquetados correctamente por el algoritmo). Tal que se presentan los resultados de las trayectorias evaluadas para:

**Tabla 8:** Un octavo de la imagen (1075x1075 px).

Posición	OHDU	Eventos	Efectivos	Muones
1	2	280	252	171
2	3	287	258	172
3	8	317	236	153
4	9	263	223	131

**Fuente:** Elaboración propia.

**Tabla 9:** Un cuarto de la imagen (2150x2150 px).

Posición	OHDU	Eventos	Efectivos	Muones
1	2	1021	924	611
2	3	1056	957	616
3	8	1178	962	607
4	9	1167	940	565

**Fuente:** Elaboración propia.

**Tabla 10:** La totalidad de la imagen (4300x4300 px).


Posición	OHDU	Eventos	Efectivos	Muones
1	2	3965	3536	2290
2	3	4240	3566	2253
3	8	4277	3632	2326
4	9	4953	3614	2263

**Fuente:** Elaboración propia.

Inicialmente, es evaluada la efectividad del algoritmo ante las dos configuraciones mas pequeñas de las imágenes antes de aplicarse a la totalidad de la imagen y de los detectores. Se describe la cantidad de eventos etiquetados, y mediante inspección visual, se detallan los eventos incorrectos y correctos a través de las imágenes:


1. Primer caso de análisis: **OHDU = 2 y OHDU = 3.**

Tamaño	Etiqueta	Correctos	Efectividad
1075x1075	74	64	86.486 %
2150x2150	284	249	87.670 %




2. Segundo caso de análisis: **OHDU = 2, OHDU = 3 y OHDU = 8.**

Tamaño	Etiqueta	Correctos	Efectividad
1075x1075	35	30	85.714 %
2150x2150	161	138	85.714 %




3. Tercer caso de análisis: **OHDU = 3 y OHDU = 8.**

Tamaño	Etiqueta	Correctos	Efectividad
1075x1075	23	20	86.956 %
2150x2150	116	103	88.793 %




4. Cuarto caso de análisis: **OHDU = 3 y OHDU = 8 y OHDU = 9.**

Tamaño	Etiqueta	Correctos	Efectividad
1075x1075	8	7	87.5 %
2150x2150	43	40	93.023 %



5. Quinto caso de análisis: **OHDU = 8 y y OHDU = 9.**


Tamaño	Etiqueta	Correctos	Efectividad
1075x1075	28	24	85.714 %
2150x2150	126	110	87.301 %



Demostrada la validez del algoritmo para el seguimiento de trayectorias, se procede a evaluar en las configuraciones mencionadas anteriormente incluyéndose la totalidad de una imagen de modo:

6. Sexto caso de análisis: **OHDU = 2, OHDU = 3, OHDU = 8 y OHDU = 9.**

Tamaño	Etiqueta	Correctos	Efectividad
1075x1075	10	9	90.00 %
2150x2150	78	65	83.333 %
4300x4300	93	79	84.946 %




5.7. **Trayectorias Incorrectas.**

Del mismo modo, aquellos eventos etiquetados erróneamente corresponden a situaciones detalladas a continuación determinadas durante la inspección manual individual de los eventos:

- La predicción del evento se encuentra solapado.
- La predicción no existe debido a que se encuentra por fuera de los límites de las imágenes.
- El evento es mal evaluado ya que pierde características de búsqueda de su predicción.
- Problemas de asimetría debido a su energía conllevan a una búsqueda en la dirección contraria a la trayectoria del evento.
- Eventos mal clasificados por el modelo determinan búsquedas incorrectas.


5.8. **Trayectorias Correctas**

Tras la ejecución del sistema en las imágenes determinadas, se presentan evaluaciones de los eventos según las trayectorias que son correctas:




**Figura 20:** Ejemplos de algunos eventos correctos a través de los OHDU para la configuración 1075x1075 px. **Fuente:** Elaboración Propia

Se muestran los eventos con menor desplazamiento (ID=15, ver Figura. 21) y mayor desplazamiento (ID=92, ver Figura. 22) para visualizar la diferencia respecto a sus tamaños que corresponde proporcionalmente a la distancia recorrido por los eventos entre los detectores.



**Figura 21:** ID=15. **Fuente:** Elaboración Propia.





**Figura 22:** ID=92 **Fuente:** Elaboración Propia

## 6. Conclusión

Este trabajo final de grado aborda el problema del seguimiento de muones entre detectores en experimentos físicos a través de un sistema inteligente de detección y predicción. Las principales conclusiones se resumen a continuación:

- Se implementaron herramientas de software especializadas en la interacción de las partículas (GEANT4) en los detectores que brindaron una base para el algoritmo de búsqueda de trayectorias en las imágenes sintéticas.
- Se extrajeron características de los eventos sintéticos para predecir el desplazamiento alcanzando eficiencias de 98.92 % en las imágenes sintéticas, representando 17 errores para 1420 eventos de interés.
- Para implementar el mejor modelo fueron evaluados todos los modelos de segmentación ofrecidos por la gama de YOLO destacándose el modelo YOLOv8l-seg brindando  $mAP(box\ 50-95)=0.74$ ,  $mAP(mask\ 50-95)=0.674$ .
- Las bases de datos empleadas en trabajos finales de grado anteriores fueron sustento inicial para la construcción de un modelo de mayor alcance al aumentar la cantidad de eventos etiquetados entrenados.
- Los resultados del modelo empleado indican la alta precisión en la clasificación de trazas muónicas, alcanzándose precisiones del 90 %, y del mismo para las clases correspondientes a los worms (77 %) y spots (70 %).
- Del mismo modo, se encontraron pérdidas de información respecto a los eventos solapados, las mismas representan un error debido a la necesidad de conocer las características de los impactos obligándonos a realizar el seguimiento en muones individuales.
- Los resultados indican que aproximadamente el 63 % de los eventos registrados corresponden a muones, 15 % representan eventos solapados, 12 % corresponde a worms, mientras que del mismo modo 5 % indican eventos no identificados como spots.

- La visualización de los eventos indican una mayor presencia de eventos de mayor traza longitudinal respecto a las simulaciones. Por ese motivo, en el algoritmo final se utilizó únicamente una de las ecuaciones del desplazamiento.

- La implementación del modelo determina una alta y constante eficiencia (eventos etiquetados correctamente) a través de los detectores para todas las configuraciones empleadas, siendo evaluadas las imágenes en secciones de un octavo, un cuarto y la totalidad de la imagen registrándose en todas efectividades superiores al 83 %.

## 7. Trabajos futuros

Los trabajos futuros que se pueden realizar a partir del estado de este trabajo se citan a continuación:

- Expandir el algoritmo a otras partículas según características de sus impactos y configuraciones tanto de detectores como de imágenes.
- Utilizar los eventos etiquetados para creación de bases de datos más detalladas.
- Expandir el modelo de Inteligencia Artificial a fin de mejorar las predicciones mediante la extracción de las características de los eventos solapados e implementar el algoritmo a fin de maximizar la cantidad de eventos detectados
- Evaluar métricas para determinar la efectividad de los eventos sin necesidad de una inspección visual a través de cada uno de los impactos.

## Referencias

- [1] M. Kiehn, S. Amrouche, P. Calafiura, V. Estrade, and S. Farrell, "The trackml high-energy physics tracking challenge on kaggle," *EPJ Web of Conferences*, p. v, 2019.
- [2] C. Adam-Bourdarios, G. Cowan, C. Germain-Renaud, I. Guyon, B. Kégl, and D. Rousseau, "The higgs machine learning challenge," *Journal of Physics: Conference Series*, vol. 664, no. 7, p. 072015, dec 2015. [Online]. Available: <https://dx.doi.org/10.1088/1742-6596/664/7/072015>
- [3] A. Aguilar-Arevalo, X. Bertou, C. Bonifazi, M. Butner, G. Cancelo, A. C. Vazquez, B. C. Vergara, C. Chavez, H. D. Motta, J. D'Olive, J. D. Anjos, J. Estrada, G. F. Moroni, R. Ford, A. Foguel, K. P. H. Torres, F. Izraelevitch, A. Kavner, B. Kilminster, K. Kuk, H. Lima, M. Makler, J. Molina, G. Moreno-Granados, J. Moro, E. Paolini, M. S. Haro, J. Tiffenberg, F. Trillaud, and S. Wagner, "The connie experiment," *Journal of Physics: Conference Series*, vol. 761, no. 1, p. 012057, oct 2016. [Online]. Available: <https://dx.doi.org/10.1088/1742-6596/761/1/012057>



- [4] J. C. Sanabria, "Búsquedas de materia oscura supersimétrica en el LHC," *Revista de la Academia Colombiana de Ciencias Exactas, Físicas y Naturales*, vol. 38, p. 34–55, nov. 2014. [Online]. Available: <https://raccefyn.co/index.php/raccefyn/article/view/153>
- [5] M. Bektasoglu and H. Arslan, "Investigation of the zenith angle dependence of cosmic-ray muons at sea level," *Pramana*, vol. 80, pp. 837–846, 2013.
- [6] J. Bremer and F. Nobels, "Characterising the cosmic rays in a CCD," *Kapteyn Astronomical Institute, Groningen*, 2015.
- [7] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics yolov8," 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [8] C. Silva, K. Aquino, J. Bernal, D. H. Stalder, J. Molina, and L. Salguero, "A particle identification in the connie experiment using deep learning approach," in *(in preparation) Proceedings of the CLEI 2023*, 2023.
- [9] A. Aguilar-Arevalo, X. Bertou, C. Bonifazi, M. Butner, G. Cancelo, A. C. Vázquez, B. C. Vergara, C. Chavez, H. D. Motta, J. D'Olive, J. D. Anjos, J. Estrada, G. F. Moroni, R. Ford, A. Foguel, K. H. Torres, F. Izraelevitch, A. Kavner, B. Kilminster, K. Kuk, H. L. Jr., M. Makler, J. Molina, G. Moreno-Granados, J. Moro, E. Paolini, M. S. Haro, J. Tiffenberg, F. Trillaud, and S. Wagner, "Results of the engineering run of the coherent neutrino nucleus interaction experiment (connie)," *Journal of Instrumentation*, vol. 11, no. 07, p. P07024–P07024, Jul. 2016. [Online]. Available: <http://dx.doi.org/10.1088/1748-0221/11/07/P07024>
- [10] F. Arneodo, M. Benabderrahmane, S. Dahal, A. Di Giovanni, L. Pazos Clemens, A. Candelà, M. DIncecco, D. Sablone, and G. Franchi, "Muon tracking system with silicon photo-multipliers," *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, vol. 799, pp. 166–171, 2015. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0168900215009316>
- [11] C. Genster, M. Schever, L. Ludhova, M. Soiron, A. Stahl, and C. Wiebusch, "Muon reconstruction with a geometrical model in JUNO," *Journal of Instrumentation*, vol. 13, no. 03, p. T03003, mar 2018. [Online]. Available: <https://dx.doi.org/10.1088/1748-0221/13/03/T03003>
- [12] N. Kume, H. Miyadera, C. Morris, J. Bacon, K. Borozdin, J. Durham, K. Fuzita, E. Gardincerri, M. Izumi, K. Nakayama, M. Saltus, T. Sugita, K. Takakura, and K. Yoshioka, "Muon trackers for imaging a nuclear reactor," *Journal of Instrumentation*, vol. 11, no. 09, p. P09008, sep 2016. [Online]. Available: <https://dx.doi.org/10.1088/1748-0221/11/09/P09008>
- [13] J. Alzubi, A. Nayyar, and A. Kumar, "Machine learning from theory to algorithms: an overview," in *Journal of physics: conference series*, vol. 1142. IOP Publishing, 2018, p. 012012.
- [14] J.-W. Lin, "Artificial neural network related to biological neuron network: a review," *Advanced Studies in Medical Sciences*, vol. 5, no. 1, pp. 55–62, 2017.
- [15] K. O'Shea and R. Nash, "An introduction to convolutional neural networks," 2015.
- [16] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel, M. Al-Amidie, and L. Farhan, "Review of deep learning: Concepts, CNN architectures, challenges, applications, future directions," *Journal of big Data*, vol. 8, pp. 1–74, 2021.